

קורס מבוא ללמידת מכונה - פרויקט מסכם

1. קובץ קוד מוכן בפורמט Jupyter notebook.	מסמכים להגשה:
2. מסמך PDF לדו"ח בשם Submission_group_<number>.pdf	
3. קובץ csv בשם Submission_group_<number>.csv אשר כולל את תחזיות הקלסיפיקציה Prediction Probabilities (מצ"ב דוגמא להגשה בקובץ example_submission.csv)	
python 3	תוכנות דרושות:
קובץ zip שיכלול את שלושת הקבצים הנ"ל – שם הקובץ בפורמט group_number.zip	אמצעי הגשה:
10.07.2026	מועד אחרון להגשה:



מבוא

בפרויקט זה יינתנו לכם נתונים אודות העברות מטען בין מתקנים לוגיסטיים ברשת הפצה אזורית. הנתונים מתארים פעילות תפעולית של חברה לוגיסטית האחראית על העברת מטענים וסחורות בין מרכזי הפצה, מתקני מיון ומרכזים תפעוליים שונים ברחבי הרשת.

הנתונים כוללים מידע תפעולי מגוון אודות כל העברה, כגון זמני יציאה והגעה מתוכננים ובפועל, מאפייני מסלול, עיכובים מסוגים שונים, מידע אודות ספק הלוגיסטיקה האחראי על ההעברה, מזהים אנונימיים של מתקנים ואזורים גיאוגרפיים, וכן מספר שדות אנונימיים נוספים אשר עשויים להכיל מידע שימושי לצורך החיזוי.

מטרתכם היא לבנות מודל חיזוי אשר יוכל להעריך, על סמך הנתונים הקיימים, האם העברה מסוימת תתעכב ביותר מ-30 דקות ביחס לזמן ההגעה המתוכנן שלה. מודל כזה עשוי לסייע לארגון בתכנון תפעולי, זיהוי צווארי בקבוק, שיפור תהליכי עבודה וקבלת החלטות בזמן אמת.

במונחים של למידת מכונה, מדובר בבעיית סיווג בינארי **Binary Classification**, כל רשומה (כלומר, העברה) צריכה להיות מסווגת לאחת משתי קטגוריות: "הגיע בזמן" או "איחר" - בהתבסס על מאפייניו.

מטרת הפרויקט היא התנסות מעשית ביישום הידע שנלמד בקורס, תוך כדי פיתוח פתרון מקצה לקצה: החל מהיכרות עם הנתונים, דרך ניתוח וניקוי הנתונים ועד בניית מודל חיזוי והערכתו. אף על פי שאין מגבלה על דרך החשיבה והיישום, קיימות הנחיות בסיסיות שעליכם לעמוד בהן לצורך הצלחת הפרויקט.

הנחיות כלליות

- אין להכין ולעצב את סט הנתונים הגולמי בעזרת אקסל (אלא בחבילות python בלבד).



- מימוש הקוד ייעשה במחברת Jupyter, ויכלול הסברים מלאים על אופי המימוש בקוד עצמו (בעזרת markdowns והערות בתוך הקוד) בבדיקה יינתן דגש על כתיבת קוד מסודר וקריא!
- משך הרצת הקוד מתחילתו ועד סופו לא יעלה על שעה.
- אין להשתמש בקבצים חיצוניים פרט ל train.csv, test.csv כאשר בקובץ ה test אין את ה- labels.
- כפי שלמדתם הסמסטר, אין חובה להשתמש בכל המסבירים של סט הנתונים. תוכלו להנדס ולעצב את המסבירים כרצונכם.
- טיב הביצועים של המודל שלכם ייעשה על ידי מטריקת AUC.
- ייפתח פורום באתר הקורס ובו ייענו שאלות בנוגע לפרויקט, שימו לב כי התגובות בפורום מחייבות עבור כלל הסטודנטים, לכן מומלץ בחום להתעדכן בו. שאלות במייל לצוות הקורס לא יענו אלא אם מדובר בעניין פרטני.
- שימושים בפונקציות וטכניקות שלא נלמדו בקורס הם מבורכים, אולם הם אינם מהווים תחליף לשיטות המסורתיות.
- עבור כל ויזואליזציה שאתם מציגים, יש לכתוב הסבר מה הסקתם ממנה ו/או איזה חלק מעניין בה. ויזואליזציה ללא הסבר תחשב כלא קיימת.
- בונס יחולק לסטודנטים לפי ביצועי המודל שלהם: 5 נקודות למקום הראשון, 3 נקודות למקום השני, נקודה למקום השלישי.
- קנס גדול יינתן על קוד שלא רץ ועל קובץ csv שלא מוגש בפורמט המבוקש. על הקוד לרוץ (ללא תקלות) בעת שינוי הניתוב ל data.
- יש לפרט את ההנחות שנלקחו בכל שלב של הפרויקט. הנחות שלא יפורטו יחשב כאילו לא נלקחו בחשבון ומצב זה עלול להוביל להורדה בציון.
- גם אם ניסתם "לפצח" את הבעיה בדרך מסוימת ואין שיפור בתוצאות: אל תסירו את הניסיון מהקוד. רק חשוב שתדגישו שמדובר בניסיון לא מוצלח ואין לו מקום ב-work flow הסופי.
- **הקובץ של המחברת יוגש עם הפלטים של הרצה.**

משימת התכנות

חלק ראשון - אקספלורציה:

חלק זה עליכם לבצע חקר נתונים מעמיק במטרה להבין את מאפייני הדאטה, לזהות דפוסים והתנהגויות מעניינות, ולבחון אילו מסבירים עשויים להיות משמעותיים לצורך משימת החיזוי. עליכם לחקור את הנתונים בכל אופן שנראה לכם רלוונטי, תוך שימוש בסטטיסטיקות תיאוריות, ויזואליזציות וניתוח קשרים בין מסבירים שונים. מומלץ לבחון את אופי ההתפלגות של כל מסביר, לזהות מגמות חריגות או מעניינות, ולבדוק האם קיימים קשרים בין מאפייני ההעברות לבין משתנה המטרה. כמו כן, עבור השאלות אשר מופיעות בסעיפים יש לענות בגוף המחברת (Markdown) בצמוד לחלקי הקוד הרלוונטיים

- האם קיימים הבדלים משמעותיים ברמת העיכובים בין אזורים גיאוגרפיים שונים או בין ספקי לוגיסטיקה שונים?
- האם שעות יציאה מסוימות במהלך היום מאופיינות בהסתברות גבוהה יותר לעיכובים?
- האם קיים קשר בין עיכובי יציאה לבין עיכובי הגעה? עד כמה עיכוב ביציאה משפיע על הסיכוי לעיכוב משמעותי בהגעה?
- האם מרחק המסלול המתוכנן משפיע על רמת העיכובים?
- האם קיימים קשרים קורלטיביים חזקים בין סוגי העיכובים השונים?
- האם קיימים מסבירים אנונימיים אשר נראים כבעלי השפעה משמעותית על משתנה המטרה?



- האם קיימים פיצ'רים אשר נראים לא רלוונטיים או בעלי תרומה נמוכה במיוחד לחיזוי?

חלק שני – עיבוד מקדים:

בחלק זה עליכם לבצע על פי ראות עיניכם את השלבים הבאים: נרמול הנתונים, התמודדות עם נתונים חריגים, התמודדות עם נתונים חסרים, התמודדות עם משתנים קטגוריאליים, התמודדות עם מימד הבעיה, הקטנת מימד הבעיה, בניית מסבירים או מניפולציה על מסבירים קיימים, החלת העיבוד על סט ה-test. ניתן לבצע את השלבים בסדר שנראה לכם כנכון ויש לתת הסבר מדוע זהו הסדר בו נעשו הדברים. וכן ניתן לבצע ניסיונות נוספים אשר לא נלמדו בקורס על מנת לעבד את המסבירים הניתנים לכם.

כמו כן, עבור השאלות אשר מופיעות בסעיפים יש לענות בגוף המחברת (Markdown) בצמוד לחלקי הקוד הרלוונטיים

- האם קיימים נתונים חריגים (Outliers) בנתונים? אם כן, עליכם להתמודד עימם ולהסביר כיצד בחרתם לעשות זאת ומדוע
- האם הנתונים מנורמלים? אם לא - האם צריך לנרמל אותם? מה החשיבות של נרמול הנתונים בבעיה?
- האם ישנם נתונים חסרים? כיצד בחרתם לטפל בהם ומדוע באופן זה?
- התמודדות עם משתנים קטגוריאליים - באיזה אופן בחרתם להתמודד עם משתנים אלו?
- חוו דעתכם על מימד הבעיה וכיצד יש להתייחס לכך בעיבוד הנתונים.

חלק שלישי – הרצת המודלים:

בחלק זה עליכם לבחור ולממש מספר מודלי למידת מכונה לצורך פתרון בעיית הסיווג שהוגדרה בפרויקט. מטרת שלב זה היא לבחון כיצד מודלים שונים מתמודדים עם מאפייני הדאטה והמסבירים שנבנו במהלך שלבי העבודה הקודמים, תוך התייחסות לבחירת ההיפרפרמטרים ולאופן יישום המודלים על סט הנתונים. בחירת מודל אחד מבין השניים הבאים והחלתם על סט הנתונים:

- KNN
- Logistic Regression
- בחירת שלושה מודלים מתקדמים מבין הארבעה הבאים והחלתם על סט הנתונים:
- Multi-Layer Perceptron (ANN)
- Decision Tree
- Random Forest or Adaptive Boosting
- Support Vector Machine

חלק רביעי – הערכת המודלים:

בחלק זה עליכם להעריך ולנתח את ביצועי המודלים השונים אשר אומנו בפרויקט. מטרת שלב זה היא להבין כיצד המודלים מתמודדים עם משימת החיזוי, להשוות בין ביצועיהם, לזהות יתרונות וחסרונות של כל מודל, ולבחון את יכולת ההכללה שלהם על נתונים שלא נראו במהלך האימון. חלק זה יכלול:

- בניית confusion matrix (מדגמית) על אחד המודלים, עליכם להסביר מה אומרים התאים בתוך המטריצה בהקשר למודל שבחרתם, כלומר מה ניתן להסיק על ביצועי המודל בהקשר זה.



- הערכת המודל באמצעות K-Fold Cross Validation ובניית פלט ROC על כל K-Fold עבור כל אחד מהמודלים שהורצו (רצוי באותו התרשים).
- פערי ביצועים בין הרצת המודל על ה-Train או על ה-Validation, האם המודל שלכם הוא Overfitted? מה עשיתם/עליכם לעשות על מנת להגדיל את יכולת ההכללה שלו?

חלק חמישי – ביצוע פרדיקציה

לאחר בחירת המודל הסופי, עליכם להשתמש בו לצורך ביצוע תחזיות על נתוני קובץ ה-test. מטרת שלב זה היא לבחון את יכולת המודל לבצע חיזוי על נתונים חדשים שלא נראו במהלך תהליך האימון והוולידציה, ולהפיק עבור כל רשומה את הסתברות הסיווג המתאימה.

בצעו תחזית על נתוני קובץ "test.csv", ולהגיש קובץ בפורמט csv בשם Submission_group_number.csv (החליפו את number למס' הקבוצה) אשר כולל את תחזיות הסתברות הסיווג (Prediction Probabilities) מצ"ב דוגמא.

הערות:

1. הערכת ביצועי המודלים צריכה להתבצע על סט **Validation** ולא על סט ה-**Train** עצמו. בחירת מודל על סמך ביצועיו על נתוני האימון בלבד עלולה להוביל ל-**Overfitting** ולהסקת מסקנות שגויות לגבי איכות המודל.
2. עבור כל מודל שבו תבחרו להשתמש, יש לפרט בצורה ברורה את ההיפר-פרמטרים שנבחרו במהלך העבודה, גם במקרים בהם נעשה שימוש בערכי ברירת המחדל של הספריות השונות.
3. סדר ביצוע השלבים בפרויקט אינו מחייב. בדומה לפרויקט Data Science אמיתיים, ייתכן שבמהלך העבודה תידרשו לחזור לשלבים קודמים, לעדכן החלטות שבוצעו במהלך עיבוד הנתונים או לשנות את אופן בניית המסבירים והמודלים בהתאם לתובנות שיעלו לאורך התהליך.

הדוח המסכם

הדו"ח יכלול לכל היותר 5 עמודים (לא כולל שער) אשר בו יוסברו כלל השלבים שנקטו במהלך ניתוח הנתונים. נדרש הסבר מפורט על הרציונל מאחורי בחירת כל אחת מהשיטות שצינו בשלבים לעיל, של ההיפר-פרמטרים שנבחרו, ותוצאות המודלים השונים. אין צורך להרחיב במילים ואין צורך לצטט את חומר הקורס בפרויקט. בהיבט פחות פורמלי, זה המקום להסביר את כלל התהליך שביצעתם. דילמות, החלטות וכו'.

- על הדו"ח לכלול פרק "תקציר מנהלים" פסקה קצרה המסכמת את הפרויקט, וכן פרק "סיכום" אשר מתאר את כלל המודלים והמסקנות שנסקרו במהלך ניתוח הנתונים.
- יש לפרט את ההנחות שנלקחו בכל שלב של הפרויקט. הנחות שלא יפורטו יחשבו כאילו לא נלקחו בחשבון ומצב זה עלול להוביל להורדה בציון.
- ניתן להוסיף נספחים ככל העולה על רוחכם (ולהפנות אליהם בקוד). ויזואליזציה תופיע בנספחים (וגם בגוף הקוד) במידה ויש גרפים בנספחים יש לציין או לתת עליהם הסבר והצביע עליהם מהדו"ח.
- יש לציין בראש הדו"ח את שמות המגישים + ת"ז.
- הדו"ח מהווה חלק בלתי נפרד מהפרויקט המסכם. הניקוד אשר הוגדר בחלקי הפרויקט השונים נשען גם על טיב תיאורם בדו"ח.

בהצלחה!